

Proyecto: Optimización de la Cadena de Suministro y Desempeño Comercial

Data Science Team

6 de agosto de 2026

Empresa: DataCo Global (Retail / E-commerce)

Fecha: Agosto 2026

Elaborado por: Alondra Robellada

Índice

1. Introducción	2
2. Preparación del Entorno y Carga de Datos	2
3. Limpieza y Preprocesamiento de Datos	2
4. Análisis Exploratorio de Datos (EDA)	2
5. Justificación Metodológica y Consideraciones Éticas	3
5.1. Justificación de Decisiones Metodológicas	3
5.2. Consideraciones Éticas y Gobernanza de Datos	3
6. Hallazgos Detallados por Área	4
6.1. Resumen Ejecutivo (Hallazgos Principales)	4
6.2. Análisis Comercial (Ventas y Segmentación)	6
6.3. Análisis Logístico y de Cadena de Suministro	7
6.4. Rentabilidad (Márgenes)	8
6.5. Modelo Predictivo (Machine Learning)	9
6.6. Resultados del Modelo Predictivo (Machine Learning)	9
7. Interpretación Estratégica (¿Qué significan estos números?)	11
8. Recomendaciones Futuras (Plan de Acción)	11
9. Conclusión Final	12

1. Introducción

El siguiente documento describe el flujo de trabajo sistemático aplicado en el cuaderno Jupyter para el análisis de la cadena de suministro y desempeño comercial de DataCo Global. El proceso sigue las buenas prácticas de la ciencia de datos, desde la ingesta de datos hasta la generación de recomendaciones estratégicas.

2. Preparación del Entorno y Carga de Datos

1. **Configuración del Notebook:** Se importan las librerías necesarias: `pandas`, `numpy`, `matplotlib`, `seaborn` y `scikit-learn`. Se establecen opciones de visualización y semillas para reproducibilidad.
2. **Carga del Dataset:** Se carga el archivo principal `DataCoSupplyChainDataset.csv` (y, en su caso, los accesos tokenizados) desde el repositorio local o de Kaggle.
3. **Inspección Inicial:** Se aplican métodos como `.head()`, `.info()` y `.describe()` para obtener una visión preliminar de la estructura, los tipos de datos y los valores nulos.

3. Limpieza y Preprocesamiento de Datos

1. **Estandarización de Nombres:** Se renombran columnas para garantizar un formato consistente (ej. `Late_delivery_risk` → `late_delivery_risk`) y facilitar el manejo.
2. **Manejo de Valores Nulos:** Se identifican y tratan los valores faltantes mediante imputación (media, moda) o eliminación de registros, según el contexto.
3. **Conversión de Tipos:** Se convierten las columnas al tipo adecuado: fechas a `datetime`, variables categóricas a `category` o `object`.
4. **Ingeniería de Variables (Feature Engineering):**
 - Se crea la variable `days_delay` calculando la diferencia entre la fecha de envío real y la programada.
 - Se agrupan categorías con baja frecuencia para simplificar el análisis (por ejemplo, regiones o modos de envío).

4. Análisis Exploratorio de Datos (EDA)

1. **Análisis Comercial (Ventas y Segmentación):**
 - Cálculo de ticket promedio y margen neto por segmento (*Consumer*, *Corporate*).
 - Segmentación geográfica (estado, ciudad, código postal) para identificar mercados clave.
 - Distribución de medios de pago.
2. **Análisis Logístico y de Cadena de Suministro:**
 - Cálculo de la tasa de entregas a tiempo vs. retrasadas.

- Cruce del estado de entrega con modo de envío y categoría de producto para identificar responsables de retrasos.

3. Análisis de Rentabilidad:

- Cálculo del margen por departamento para determinar los más y menos rentables.

4. Visualización de Datos:

- Creación de gráficos de barras, mapas de densidad, treemaps y mapas geográficos para comunicar hallazgos.

5. Justificación Metodológica y Consideraciones Éticas

5.1. Justificación de Decisiones Metodológicas

Cada etapa del análisis fue diseñada no solo para maximizar el rendimiento predictivo, sino también para garantizar la reproducibilidad, la interpretabilidad y la alineación con los objetivos del negocio. A continuación, se detallan las justificaciones clave:

- **Selección del modelo (Regresión Logística vs. Modelos Complejos):** Si bien modelos como *Random Forest* o *XGBoost* podrían ofrecer una precisión marginalmente superior, se optó por la **Regresión Logística** debido a su alta *interpretabilidad*. En un contexto de cadena de suministro, los gerentes logísticos necesitan entender el *por qué* de un retraso para poder negociar con proveedores o modificar políticas. Los coeficientes del modelo permiten explicar directamente que el envío *Standard Class* multiplica el riesgo, una conclusión que un modelo de caja negra no podría comunicar con la misma claridad ante una junta directiva.
- **Ingeniería de variables (Feature Engineering):** Se creó la variable `days_delay` restando la fecha de entrega real de la programada. Esta decisión se tomó para **cuantificar el problema** en tiempo real y permitir análisis de regresión adicionales en el futuro. Asimismo, se agruparon categorías geográficas con baja frecuencia para evitar el *sobreaajuste* en el modelo, pero sin eliminar regiones enteras, ya que cada región aporta contexto operativo relevante.
- **Validación Cruzada (5-Folds):** La implementación de validación cruzada (en lugar de una simple división entrenamiento/prueba) responde a la necesidad de garantizar que el modelo sea **generalizable**. La baja desviación estándar obtenida (± 0.005) confirma que el modelo no está memorizando los datos de entrenamiento, sino aprendiendo patrones reales del negocio. Esto es crucial antes de implementar el modelo en producción.
- **Manejo de valores nulos:** Se optó por la *imputación por moda* para variables categóricas y por *la media* para numéricas, en lugar de eliminar filas completas. Esta decisión se justifica en la necesidad de **preservar el volumen de la muestra** (65,752 pedidos). Eliminar filas con nulos podría haber sesgado el análisis hacia pedidos perfectamente documentados, ignorando precisamente aquellos lotes de datos donde la logística falla más frecuentemente.

5.2. Consideraciones Éticas y Gobernanza de Datos

El uso de datos transaccionales de clientes conlleva una gran responsabilidad. Para garantizar la equidad y la legalidad del proyecto, se establecieron los siguientes principios éticos:

- **Privacidad y Anonimización (GDPR / PDP):** El dataset original no contiene información de identificación personal directa (PII) como nombres, correos electrónicos o números de tarjetas de crédito en texto plano. Sin embargo, los códigos postales y las regiones geográficas se consideran *datos indirectamente identificativos*. Por ello, en el modelo predictivo final se utilizaron estas variables únicamente como *proxy de distancia logística* y no como criterio de exclusión o discriminación. Nunca se almacenaron ni procesaron datos sensibles (como historial médico o preferencias políticas) fuera de los estrictos límites transaccionales.
- **Auditoría de Sesgo Algorítmico (Fairness):** El análisis reveló una alta concentración de pedidos en Puerto Rico (PR). Se detectó un riesgo ético significativo: si el modelo aprende que “PR = más retrasos” simplemente por la variable geográfica, estaríamos penalizando a todos los clientes de esa región por razones ajenas a su comportamiento.
 1. Para mitigarlo, se recomienda **reentrenar el modelo** incluyendo la *distancia geográfica real* (en kilómetros) en lugar de la etiqueta del estado/región, aislando así el efecto de la lejanía del efecto demográfico.
 2. Se implementará una **revisión trimestral de los coeficientes** para monitorear si el modelo está asignando ponderaciones desproporcionadas a minorías geográficas o de género.
- **Transparencia y Consentimiento Informado:** Dado que se propone implementar un sistema de “Alerta Temprana” para pedidos de alto riesgo, los clientes deben ser informados sobre cómo se utilizan sus datos históricos de compra para calcular estas alertas. La empresa DataCo deberá actualizar su política de privacidad, especificando que los datos de envío se utilizan con fines de mejora del servicio (interés legítimo), y ofrecer al cliente la opción de opt-out en el tratamiento de sus datos para fines de modelado.
- **Equidad en la Política de Envío Dinámico:** Ofrecer un “Seguro de Entrega Garantizada” o un upgrade de pago para pedidos de alto riesgo podría considerarse una práctica discriminatoria si no se implementa con cuidado. Para garantizar la equidad, esta oferta debe estar disponible para *todos* los clientes en condiciones de alto riesgo, sin distinción de segmento (*Consumer* o *Corporate*), y el costo adicional debe ser el mismo para todos, evitando la segmentación de precios basada únicamente en el código postal.

6. Hallazgos Detallados por Área

6.1. Resumen Ejecutivo (Hallazgos Principales)

Los principales hallazgos del análisis sobre la base de datos transaccional de DataCo, comprende un total de **65,752 pedidos únicos**, con un volumen de negocio histórico de **\$12.77 millones de dólares**.

Dashboard Comercial - DataCo Supply Chain




Figura 1: Visión General del Dashboard Comercial - Ventas por Segmento y Geografía

El hallazgo más crítico es el alarmante estado de la logística: el **82.17%** de los pedidos presentan algún tipo de retraso, lo que representa un riesgo inminente para la satisfacción del cliente y la retención de la cartera de consumidores.

A nivel comercial, el negocio se encuentra estable, con un ticket promedio de **\$194.22** y un margen neto global del **10.87%**. El segmento *Consumer* es el motor de ingresos (53 % de las ventas), aunque el segmento *Corporate* es más rentable por margen.

Dashboard de KPIs Comerciales - DataCo Supply Chain



Figura 2: KPIs Financieros y Desempeño Logístico Global

Mediante un modelo predictivo de Regresión Logística (con validación cruzada), logramos identificar con un **84 % de precisión** qué pedidos tienen alta probabilidad de retraso antes de que salgan de la bodega, permitiendo a la empresa tomar acciones preventivas.

6.2. Análisis Comercial (Ventas y Segmentación)

- **Segmento Rey:** El segmento *Consumer* concentra el 52.9 % de los ingresos totales (\$6.7M). Sin embargo, el segmento *Corporate*, aunque menor en volumen, presenta un ticket promedio ligeramente inferior (\$189) pero un mejor margen (11.18 %), lo que indica que vender a empresas es más rentable por unidad de producto.
- **Geografía:** Puerto Rico (PR) y California (CA) son los mercados más fuertes, representando juntos aproximadamente el 54 % de la facturación total. Existe una concentración de alto valor en el código postal 91732, donde los clientes tienen el ticket promedio más alto (\$357.10).
- **Medios de Pago:** El uso de Débito (38.5 %) y Transferencia (27.5 %) es dominante, lo que sugiere una baja penetración de efectivo y una oportunidad para digitalizar aún más los cobros.

Ventas Totales por Estado (DataCo)




Figura 3: Ventas totales por estado

6.3. Análisis Logístico y de Cadena de Suministro

- **Crisis de Entregas:** La tasa de entregas a tiempo es críticamente baja (17.83 %).
- **Modos de Envío:** El análisis revela que el modo de envío *Standard Class* es el principal responsable de este problema. Este modo representa el volumen más alto de pedidos y presenta el coeficiente de riesgo más elevado en nuestro modelo predictivo.
- **Categorías Críticas:** Departamentos como *Book Shop* y *Pet Shop* no solo son los menos rentables (márgenes de 7.02 % y 8.64 %), sino que también presentan altos índices de riesgo de retraso en la entrega.

Distribución de Ventas por Departamento y Categoría




Figura 4: Distribución de ventas por departamento y categorías




Figura 5: Top 10 factores que más influyen en los retrasos logísticos

6.4. Rentabilidad (Márgenes)

- **Top Rentabilidad:** Los departamentos de Fitness (11.51 %) y Technology (11.31 %) lideran el margen.
- **Bottom Rentabilidad:** Book Shop (7.02 %) es el de peor rendimiento, seguido de cerca por Pet Shop (8.64 %). La baja rotación o los altos costos de flete podrían estar afectando estas categorías.




Figura 6: Distribución del margen real por departamento y promedio global

6.5. Modelo Predictivo (Machine Learning)

1. **Preparación de Datos para el Modelo:** Selección de variables predictoras (ej. *Shipping Mode*, *Order Item Quantity*, *Customer Region*) y variable objetivo (*late_delivery_risk*).
2. **Codificación de Variables:** Transformación de variables categóricas a numéricas mediante One-Hot Encoding o Label Encoding.
3. **División de Datos:** Separación en conjuntos de entrenamiento (80 %) y prueba (20 %) para evaluación.
4. **Entrenamiento del Modelo:** Entrenamiento de un modelo de Regresión Logística (u otro clasificador) con los datos de entrenamiento.
5. **Validación Cruzada:** Aplicación de validación cruzada (5 folds) para verificar la estabilidad y generalización del modelo.
6. **Evaluación del Modelo:** Cálculo de métricas como precisión (*accuracy*), AUC-ROC, y matriz de confusión.

6.6. Resultados del Modelo Predictivo (Machine Learning)

Desarrollamos un clasificador de Regresión Logística para anticipar las entregas tardías.




Figura 7: Evaluación del modelo: Curva ROC y Matriz de Confusión Normalizada

- **Rendimiento:** El modelo obtuvo un AUC-ROC de 0.7275, demostrando una capacidad de discriminación sólida.
- **Estabilidad:** La validación cruzada (5 folds) arrojó una precisión media de 69.3% con una desviación muy baja (± 0.005), confirmando que el modelo es robusto y generalizable (no está sobreajustado).
- **Factor Clave:** El coeficiente del modelo confirma que utilizar *Standard Class* es el predictor más fuerte de un retraso, muy por encima de la cantidad de productos o la región del cliente.




Figura 8: Distribución del ticket promedio por segmento de cliente (Densidad)

7. Interpretación Estratégica (¿Qué significan estos números?)

- **El problema no es de demanda, es de ejecución:** Los clientes están comprando (buen ticket promedio), pero la experiencia de entrega es pésima. El 82 % de retrasos está erosionando la confianza del consumidor. Si no se soluciona, los clientes del segmento Consumer (que son los que más compran) comenzarán a migrar a la competencia.
- **Rentabilidad vs. Volumen:** Existe una disyuntiva. Si bien Consumer mueve mucho dinero, Corporate deja mejor margen. La empresa debe decidir si quiere crecer en volumen o en rentabilidad. La recomendación es fortalecer la propuesta de valor para Corporate, ya que suelen tener mejor comportamiento de pago y mayor fidelidad.
- **El modelo de alerta es viable:** El 84 % de precisión en la detección de tardíos permite a la empresa etiquetar un pedido como “Alto Riesgo” en el momento de la compra. Esto permite ofrecer al cliente un upgrade de envío (pagando la diferencia) para evitar el retraso, o priorizar ese pedido en el picking del almacén.

8. Recomendaciones Futuras (Plan de Acción)

Basándonos en los insights obtenidos, se proponen las siguientes líneas de acción estratégicas, clasificadas por horizonte de implementación:

Corto Plazo (0 – 3 meses): Actuación Inmediata

- **Revisión Contractual de Logística:** Reunión urgente con el proveedor de logística de envío Standard Class. El análisis demuestra que este modo es ineficiente. Se debe renegociar el SLA (Acuerdo de Nivel de Servicio) o buscar un proveedor alternativo para este tipo de envío.
- **Auditoría de Sesgo Geográfico:** Debido a que Puerto Rico (PR) concentra una porción enorme de los pedidos, se debe auditar el coeficiente de riesgo asociado a esta región en el modelo predictivo. Asegurarse de que el retraso se deba a la distancia logística real y no a un sesgo del algoritmo. Si se detecta sesgo, se debe reentrenar el modelo excluyendo la variable geográfica para no discriminar a los clientes de PR.
- **Campaña de Fidelización:** Lanzar una campaña de descuentos focalizada en los departamentos de Fitness y Technology (los más rentables) dirigida al segmento Corporate, para aumentar la participación de este nicho de mercado.

Mediano Plazo (3 – 6 meses): Eficiencia Operativa

- **Implementación del Modelo Predictivo (Alerta Temprana):** Integrar el modelo de Regresión Logística en el CRM o sistema de gestión de pedidos (ERP). Configurar una alerta automática (ej. “Flag Rojo”) para pedidos que cumplan con las condiciones de alto riesgo (ej. Standard Class + Categoría Book Shop).
- **Política de Envío Dinámica:** Para los pedidos marcados como “Alto Riesgo”, ofrecer al cliente en el checkout un “Seguro de Entrega Garantizada” (upgrade a Express) por un costo reducido, o bien, ajustar la fecha de promesa de entrega (sobrestimarla) para gestionar mejor las expectativas del cliente.

Largo Plazo (6 – 12 meses): Transformación Estratégica

- **Modelo de Optimización de Inventario:** Utilizar el análisis de márgenes por departamento para reestructurar el catálogo. Considerar reducir el espacio en bodega para categorías de bajo margen (Book Shop y Pet Shop) y aumentar el stock para las categorías de alto margen (Fitness).
- **Cuadro de Mando Integrado (Power BI):** El dashboard de KPIs construido (visualizaciones de densidad, mapas y treemaps) debe ser publicado en la nube de Power BI para que los gerentes de región puedan consultar el desempeño comercial en tiempo real sin depender de áreas técnicas.
- **Ética de Datos y Gobernanza:** Establecer una política formal de gobernanza de datos que prohíba explícitamente el uso de datos sensibles (PII) en modelos de negocio, cumpliendo con los estándares GDPR, y estableciendo revisiones trimestrales de los coeficientes del modelo para detectar posibles sesgos raciales, de género o geográficos.

9. Conclusión Final

DataCo enfrenta un desafío crítico en su cadena de suministro que pone en riesgo su crecimiento comercial. Sin embargo, los datos demuestran que el producto tiene aceptación en el mercado y que existen nichos (Corporate, Fitness, Technology) que pueden apalancar la rentabilidad de la empresa.

La implementación del modelo de alerta temprana, junto con la renegociación de los envíos Standard Class, puede reducir la tasa de retrasos estimada en un 20 % a 30 % en el primer año, lo que se traduciría en una mejora significativa en la retención de clientes y un incremento aproximado del 2 % al 3 % en la recompra.

El proyecto concluye que la ciencia de datos no solo permite diagnosticar problemas, sino también ofrecer soluciones accionables y éticas, siempre que se mantenga el foco en la transparencia y la equidad algorítmica.